



基于零样本学习的高光谱图像分类

潘尔婷，马泳，黄珺*，樊凡，李皞，梅晓光，马佳义

武汉大学 电子信息学院

自强弘毅 求是拓新



目 录

1 研究背景

2 算法设计

3 实验分析

4 总结展望

自强弘毅 求是拓新



1

研究背景

- 选题背景及意义
- 问题定义

自强弘毅 求是拓新



选题背景及意义

研究背景

算法设计


实验分析

总结展望

自强弘毅
求是拓新



旋翼无人机高光谱成像系统



便携式地面高光谱成像系统

● 应用背景

- ✓ 小型化，便携化高光谱传感器的发展大大降低了高光谱数据的获取成本
- ✓ 高光谱数据的应用依赖于详细且可靠的标注



选题背景及意义

研究背景

- 现有分类算法存在问题

- 分类性能被过优估计

公共数据集少，模型在单个数据集上进行训练和测试


随机采样策略引起数据在空间上重叠

算法设计


实验分析

总结展望


自强弘毅
求是拓新



(a) HSI data cube



(b) Training set



(c) Testing set



选题背景及意义

研究背景

算法设计

实验分析

总结展望

自强弘毅
求是拓新

- 现有分类算法存在问题

- 分类性能被过优估计
- 模型泛化性能差

有监督分类器要求每类有足够的训练样本

高光谱数据人工标注成本高，难度大，有标签数据少

训练样本不足，模型无法直接迁移到新的数据集上

- 解决方案

跨数据集对分类模型进行训练和评估



问题定义

研究背景

算法设计

实验分析

总结展望

自强不息
求是拓新

- 有监督分类模型

已知: $x \in \mathcal{X}, y \in \mathcal{Y}$

目标: $f: \mathcal{X} \rightarrow \mathcal{Y}$




- 跨数据集分类模型

已知: $x \in \mathcal{X}, y \in \mathcal{Y}$

目标: $f: \mathcal{X} \rightarrow \mathcal{Y}'$

($\mathcal{Y} \neq \mathcal{Y}'$, 甚至 $\mathcal{Y} \cap \mathcal{Y}' = \emptyset$)



➤ 解决方案: 参考零样本学习, 引入标签语义信息

$y \rightarrow z$
 $y' \rightarrow z$



2

算法设计

- 特征提取
- 特征映射
- 标签推理

自强弘毅 求是拓新



特征提取

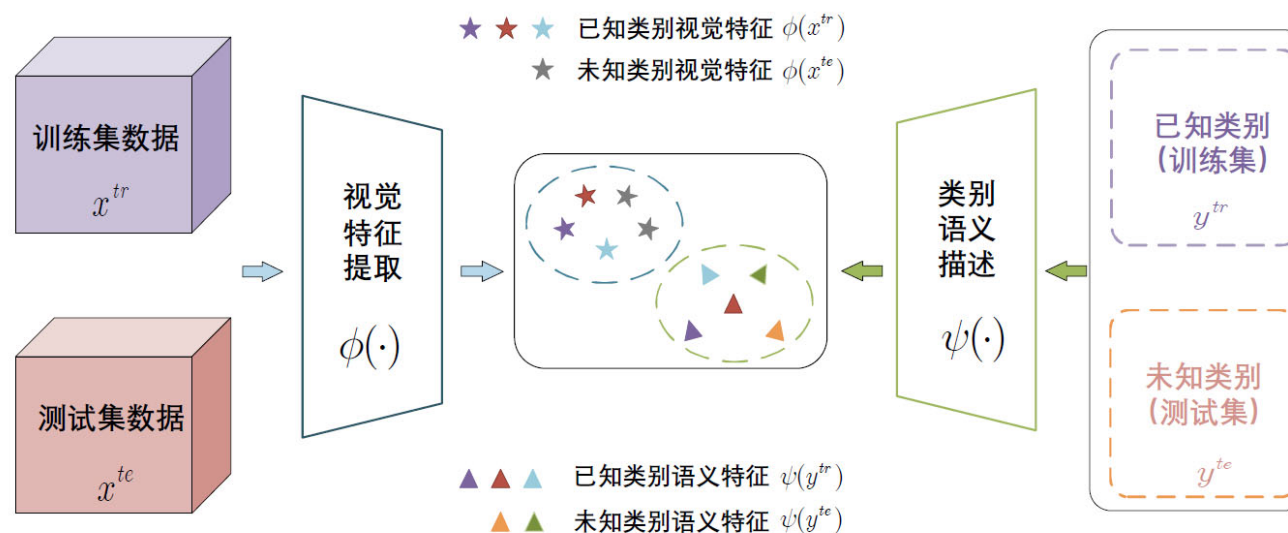
研究背景

算法设计

实验分析

总结展望

自强弘毅
求是拓新



- 视觉特征提取：高光谱数据 $\xrightarrow{\text{特征提取模型}}$ 视觉特征空间
- 类别语义描述：类别名称 $\xrightarrow{\text{词向量模型}}$ 语义特征空间



特征映射

研究背景

算法设计

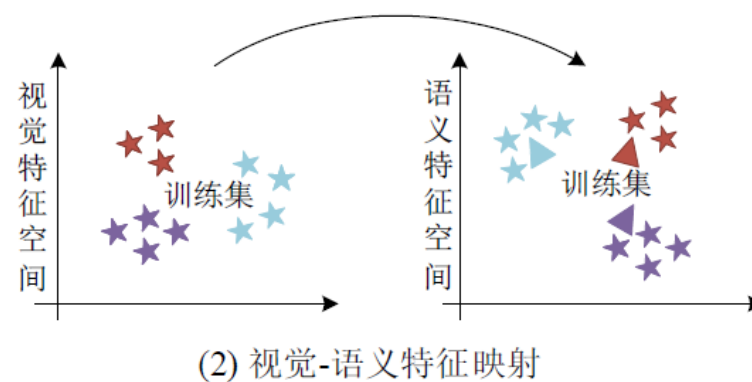
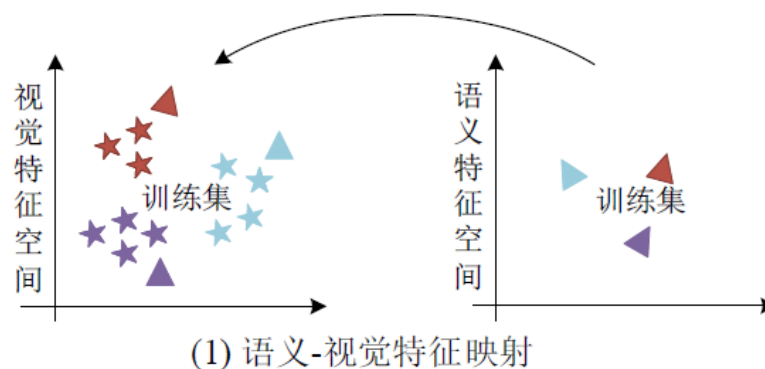
实验分析

总结展望

自强弘毅
求是拓新

- 通过将特征映射到同一特征空间来学习视觉特征和语义特征的对应关系

- ✓ 语义→视觉 特征映射
- ✓ 视觉→语义 特征映射





标签推理

研究背景

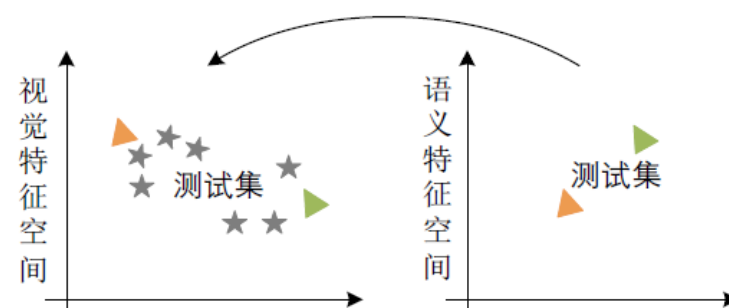
算法设计

实验分析


总结展望

自强弘毅
求是拓新

- 将学习到的映射迁移至测试集数据，利用度量学习的方法来衡量两种特征的相似度，推理出最合适的标签



(1) 语义-视觉标签推理



(2) 视觉-语义标签推理



3

实验分析

- 实验设置
- 实验结果

自强弘毅 求是拓新



实验设置

研究背景

算法设计

实验分析

总结展望

自强弘毅
求是拓新

● 数据集选择及划分


➤ 选择同一传感器采集的数据集为一组

Indian Pines (IP) & Salinas (SA)

均使用AVIRIS传感器采集，
光谱覆盖波段为400-2500nm

➤ 两种训练-测试组合

IP-SA & SA-IP



Indian Pines



Salinas

编号	SA		IP	
	名称	数量	名称	数量
1	Brocoli_green_weeds_1	2009	Alfalfa	46
2	Brocoli_gree_weeds_2	3726	Corn-notill	1428
3	Fallow	1976	Corn-mintill	830
4	Fallow_rough_plow	1394	Corn	237
5	Fallow_smooth	2678	Grass-pasture	483
6	Stubble	3959	Grass-trees	730
7	Celery	3579	Grass-pasture-mowed	28
8	Grapes_unstrained	11271	Hay-windrowed	478
9	Soli_vinyard_develop	6203	Oats	20
10	Corn_seneseed_green_weeds	3278	Soybean-notill	972
11	Lettuce_romaine_4wk	1068	Soybean-mintill	2455
12	Lettuce_romaine_5wk	1927	Soybean-clean	593
13	Lettuce_romaine_6wk	916	Wheats	205
14	Lettuce_romaine_7wk	1070	Woods	1265
15	Vinyard_untrained	7268	Building-Grass-Trees-Drives	386
16	Vinyard_vertical_trellis	1807	Stone-Steel-Towers	93



实验设置

研究背景

算法设计

实验分析

总结展望

自强弘毅
求是拓新

- 实验对比算法

- 特征提取

- ✓ 视觉特征提取：RNN, SSUN

- ✓ 语义特征提取：word2vec

- 特征映射&标签推理：

- ✓ $V \rightarrow S$: DeVise, WLE (Word Label Embedding), SAE (Stacked AutoEncoder),

- ✓ $S \rightarrow V$: SAE, DEM(Deep Embedding Model), RN(Relation Network)

- 定量评价指标：Top-k 精度



实验结果

研究背景

算法设计

实验分析

总结展望

自强弘毅
求是拓新

精度	模型	映射 方向	SA-IP		IP-SA	
			RNN	SSUN	RNN	SSUN
Top1	DeVise	V→S	13.46	15.02	10.95	12.57
	WLE	V→S	8.57	10.89	6.82	7.33
	SAE	V→S	10.14	11.03	6.04	8.46
		S→V	11.03	12.09	7.92	7.29
	DEM	S→V	16.65	20.87	10.63	9.05
	RN	S→V	19.87	13.75	13.26	14.11
Top3	DeVise	V→S	28.36	31.21	24.52	26.83
	WLE	V→S	22.49	23.76	16.14	20.04
	SAE	V→S	23.57	26.88	15.37	23.15
		S→V	27.69	25.41	16.94	22.97
	DEM	S→V	28.35	34.02	23.85	26.08
	RN	S→V	31.67	28.36	29.82	37.46

实验分析：

- 学习类别不够，测试类别较多
SA-IP：训练16个类别，测试12个类别
IP-SA：训练12个类别，测试16个类别
- 类别语义相差小
- 语义特征和视觉特征的鸿沟
- 整体模型没有进行协同训练



实验结果

研究背景

算法设计

实验分析

总结展望

自强弘毅
求是拓新

Acc	Model	V/S	SA-IP (12)			IP-SA (16)		
			Bands-grouping RNN	ResNet18	SSAN	Bands-grouping RNN	ResNet18	SSAN
Top1	DeVise	$V \rightarrow S$	13.83	10.67	15.87	10.77	11.44	13.25
	WLE	$V \rightarrow S$	8.64	8.57	11.60	6.91	10.52	6.96
	SAE	$V \rightarrow S$	9.54	10.50	11.27	5.58	9.01	7.23
		$S \rightarrow V$	10.08	8.12	12.16	7.81	12.66	7.35
	DEM	$S \rightarrow V$	17.48	17.11	22.65	12.41	12.03	8.28
	RN	$S \rightarrow V$	20.21	13.79	14.60	13.59	13.25	14.25
Top3	DeVise	$V \rightarrow S$	28.23	24.14	31.60	24.87	23.89	30.21
	WLE	$V \rightarrow S$	23.33	21.92	26.88	16.63	24.18	21.79
	SAE	$V \rightarrow S$	23.92	23.37	26.70	15.83	16.15	22.24
		$S \rightarrow V$	29.11	25.11	25.52	14.49	14.57	24.72
	DEM	$S \rightarrow V$	28.42	31.50	36.10	25.48	24.29	28.68
	RN	$S \rightarrow V$	32.76	28.44	29.28	30.22	28.78	38.09

实验分析:

- 数据集在地物类别名称接近, 语义相差小
- 语义特征和高光谱特征的鸿沟
- 整体模型没有进行协同训练



4

总结与展望

- 全文总结
- 未来展望

自强弘毅 求是拓新



基于零样本学习的高光谱图像分类

研究背景

算法设计

实验分析

总结展望

● 全文总结

- 针对高光谱分类算法在单一数据集上训练和评估导致训练不足，模型泛化性能差的缺点，本文提出在高光谱分类中引入标签语义信息，以实现跨数据集进行分类模型的训练与评估；
- 本文实验结果表明，视觉-语义映射的模式能更好地学习到高光谱数据的两种特征之间的关联。

● 未来展望

- 在更专业的语料库中训练高光谱数据标签的语义特征
- 语义特征和高光谱特征对齐问题

自强弘毅
求是拓新



谢谢！

潘尔婷

武汉大学电子信息学院

panerting@whu.edu.cn

自强弘毅 求是拓新